

Movie-Review emotion classifier

Github repo: <https://github.com/TgDSML/Movie-review-emotion-classifier/tree/main>

Μάθημα: Μηχανική Μάθηση

Ομάδα μελέτης: Νίκος Μάριος Σπυρόπουλος | MTN 2525

Μιχάλης Μυκωνιάτης | MTN 2518

Θοδωρής Γρηγορίου | MTN 2506

Σκοπός - Περιγραφή

- Συλλογή και προεπεξεργασία δεδομένων
- Exploratory Data Analysis
- Εκπαίδευση μοντέλων μηχανικής μάθησης
- Κατηγοριοποίηση κειμένων reddit σε κατηγορία συναισθήματος
- Αξιολόγηση και σύγκριση αποτελεσμάτων
- Γενίκευση σε δεδομένα reviews ταινιών και κατηγοριοποίησής τους

Dataset

Για την εργασία χρησιμοποιήθηκε το σύνολο δεδομένων [dair-ai/emotion](https://huggingface.co/datasets/dair-ai/emotion), το οποίο περιλαμβάνει σύντομα σχόλια χρηστών από μέσα κοινωνικής δικτύωσης, τα οποία είναι Labeled με έξι κατηγορίες συναισθήματος: sadness, joy, love, anger, fear, surprise.

Χαρακτηριστικά dataset :

- multilabel classification
- Σύντομα και θορυβώδη κείμενα
- Ανισορροπία κλάσεων
- Σύνολο train set: 16000 samples
- Σύνολο test set: 2000 samples
- Class labels : 6

Κάθε δείγμα του dataset αποτελείται από:


- Γραπτό κείμενο (text)
- Μια ετικέτα (label), η οποία αντιστοιχεί σε μία από τις έξι κατηγορίες συναισθήματος

Για τις ανάγκες της ανάλυσης και της προεπεξεργασίας, δημιουργήθηκαν επιπλέον χαρακτηριστικά (feature engineering) όπως:

- Μήκος κειμένου σε χαρακτήρες
- Αριθμός λέξεων στο αρχικό αλλά και στο cleaned κείμενο


Κατανομή Κλάσεων Συναισθημάτων

Το dataset παρουσιάζει έντονη ανισορροπία μεταξύ των κλάσεων (class imbalance), με τα συναισθήματα Joy και Sadness να εμφανίζονται σημαντικά συχνότερα σε σχέση με τις υπόλοιπες κατηγορίες, ενώ το surprise αποτελεί την λιγότερο εμφανιζόμενη κλάση.




Άλλα ποιοτικά χαρακτηριστικά

Μήκος κειμένων μετά την προεπεξεργασία, με βάση τον αριθμό λέξεων



Συχνότερες λέξεις ανά Label συναισθήματος αφαιρώντας τις 60 πρώτες.



Εξαγωγή Χαρακτηριστικών (Feature Extraction)

Μετατροπή των δεδομένων που βρίσκονται σε μορφή κειμένου σε αριθμητικές αναπαραστάσεις. Χρησιμοποιήθηκαν οι εξής μέθοδοι:

- TF IDF (Term Frequency - Inverse Document Frequency)
- GloVe word Embeddings
- Word2Vec Embeddings

Για κάθε μέθοδο υπάρχει notebook με απλά παραδείγματα ώστε να είναι ξεκάθαρος ο τρόπος που μετατρέπει η καθεμία την φυσική γλώσσα σε machine readable διανύσματα

TF IDF (Term Frequency - Inverse Document Frequency)

- Ο όρος Term Frequency (TF) αποτυπώνει πόσο συχνά εμφανίζεται μια λέξη μέσα σε ένα συγκεκριμένο κείμενο.
- Ο όρος Inverse Document Frequency (IDF) μειώνει το βάρος των λέξεων που εμφανίζονται σε πολλά διαφορετικά κείμενα.
- Το αποτέλεσμα λοιπόν είναι να αποδίδεται χαμηλό βάρος σε λέξεις που είναι πολύ συχνές σε όλα τα κείμενα, ενώ ενισχύει λέξεις που είναι περισσότερο χαρακτηριστικές για συγκεκριμένα κείμενα
- Κάθε κείμενο αναπαρίσταται ως ένα διάνυσμα, στο οποίο κάθε θέση αντιστοιχεί σε μία λέξη του λεξιλογίου και η τιμή της λέξης δίνεται από το αντίστοιχο TF-IDF βάρος
- Χρήση τόσο unigrams(βάρος σε μεμονωμένες λέξεις) όσο και bigrams (βάρος σε δυάδες λέξεων)

Time Frequency $TF(t, d) = \text{number of times term } t \text{ appears in a document } d / \text{total number of terms in the document } d$
Inverse Document Frequency $IDF(t, D) = \log(\text{number of documents in corpus } D / \text{number of documents containing term } t)$

$$TF-IDF(t) = TF(t) \times IDF(t)$$

GloVe word Embeddings

Κατασκευάζει έναν πίνακα συν-εμφάνισης (co-occurrence matrix) όπου μετρά πόσο συχνά δύο λέξεις εμφανίζονται κοντά η μία στην άλλη μέσα σε ένα παράθυρο συμφραζομένων και στη συνέχεια εκπαιδεύει τα διανύσματα έτσι ώστε το εσωτερικό γινόμενο δύο διανυσμάτων να προσεγγίζει την πληροφορία συν-εμφάνισης του αντίστοιχου ζεύγους λέξεων ακολουθώντας τα εξής βήματα:

- Με το Tokenizer της Keras φτιάχνει λεξιλόγιο από τα training κείμενα και μετατρέπουμε τις λέξεις σε ακέραια ids
- Διαβάζει το glove.6B.100d.txt και χτίζει την embedding matrix, δηλαδή έναν πίνακα που αντιστοιχίζει κάθε id λέξης στο αντίστοιχο GloVe διάνυσμα (ό,τι δεν βρεθεί μένει μηδενικό)
- Εφαρμόζει pad_sequences ώστε όλες οι ακολουθίες να έχουν κοινό μήκος
- Φτιάχνοντας την συνάρτηση sequences_to_vectors:για κάθε κείμενο έχω ένα σταθερού μήκους διάνυσμα χαρακτηριστικών

Word2Vec Embeddings

Είναι ένα νευρωνικό δίκτυο που μαθαίνει διανυσματικές αναπαραστάσεις λέξεων προβλέποντας το context (γειτονικές λέξεις) για κάθε λέξη-στόχο. Απαραίτητες για το μοντέλο μας ήταν οι παρακάτω προσαρμογές στην υλοποίηση

- Tuning Παραμέτρων: Ενώ η default διάσταση των διανυσμάτων είναι συνήθως 100, προχωρήσαμε σε αύξηση της διάστασης του διανύσματος (vector size) στο 300 και η αύξηση των εποχών εκπαίδευσης (epochs) σε 50
- Concatenation Mean & Max Pooling

Data Augmentation

Αφορά αποκλειστικά το training set και σκοπός της η δημιουργία παραλλαγών των υπάρχοντων κειμένων μέσω συνωνύμων και μικρών μετασχηματισμών αλλά και η ενίσχυση των μειοψηφικών κλάσεων.

Η διαδικασία:

- αντικατάσταση λέξεων με συνώνυμες
- εξαίρεση από τη διαδικασία αντικατάστασης λέξεων που σχετίζονται άμεσα με το συναίσθημα και εκφράσεις άρνησης
- Πολύ σύντομα κείμενα εξαιρέθηκαν από την διαδικασία (`num_words < 2`),
- χρησιμοποιήθηκε σταθερό random seed ώστε η διαδικασία να παράγει συνεπή αποτελέσματα σε επαναλαμβανόμενες εκτελέσεις

Class Balance - Augmentation

Στα μοντέλα που κατασκευάστηκαν με διαφορετικούς ταξινομητές ,για να επιτευχθεί η στοχευμένη εξισορρόπηση κλάσεων, οι μειοψηφικές κλάσεις εμπλουτίστηκαν με επιπλέον παραδείγματα έως ότου προσεγγίσουν το πλήθος δειγμάτων της μεγαλύτερης κλάσης.

Η τελική μορφή του train set περιλαμβάνει τόσο τα αρχικά όσο και τα εμπλουτισμένα δείγματα

Παρακάτω παρουσιάζονται τα μοντέλα που εκπαιδεύτηκαν με και χωρίς class Balance augmentation και το αντίκτυπο που είχε στα μοντέλα το augmentation μετά την εξαγωγή χαρακτηριστικών

Μοντέλα που εκπαιδεύτηκαν

- Multiclass Logistic Regression με TF-IDF αναπαράσταση, GloVe embeddings, Word2Vec embeddings
- Linear SVM με TF-IDF αναπαράσταση, GloVe embeddings, Word2Vec embeddings
- XGBoost (eXtreme Gradient Boosting) με TF-IDF αναπαράσταση, GloVe embeddings, Word2Vec embeddings

Οι παραπάνω ταξινομητές εκπαιδεύτηκαν τόσο στο original training set όσο και στο augmented

Linear Svm results

Feature Extraction Method	Augmentation	Macro F1	Accuracy
TF-IDF	No	0.8009	0.859
TF-IDF	Yes	0.7759	0.842
GloVe embeddings	Yes	0.4846	0.529
Word2Vec embeddings	No	0.4040	0.500
Word2Vec embeddings	Yes	0.5074	0.534

Multiclass Logistic Regression results

Feature Extraction Method	Augmentation	Macro F1	Accuracy
TF-IDF	No	0.8295	0.8685
TF-IDF	Yes	0.8248	0.8715
GloVe embeddings	No	0.4918	0.5380
GloVe embeddings	Yes	0.4948	0.5460
Word2Vec embeddings	No	0.3930	0.5275
Word2Vec embeddings	Yes	0.5162	0.5515

XGBoost results

Feature Extraction Method	Augmentation	Macro F1	Accuracy
TF-IDF	No	0.8113	0.8550
TF-IDF	Yes	0.8321	0.8600
GloVe embeddings	No	0.6524	0.7150
GloVe embeddings	Yes	0.6984	0.7285
Word2Vec embeddings	No	0.3087	0.4815
Word2Vec embeddings	Yes	0.5202	0.5290

Καλύτερα μοντέλα ανά ταξινομητή

TF-IDF (unigrams + bigrams) + Linear SVM Accuracy:

- Accuracy: 0.8590
- Macro-averaged Macro-averaged F1-score: 0.8009


TF-IDF (unigrams + bigrams) + Multiclass Logistic Regression + Data Augmentation

- Accuracy: 0.8725
- Macro-averaged F1-score: 0.8252


TF-IDF (unigrams + bigrams) + XGBOOST + Data Augmentation

- Accuracy: 0.88 Macro-averaged
- Macro-averaged Macro-averaged F1-score: 0.850141


Confusion matrix TF-IDF + XGBOOST + Data Augmentation



Confusion matrix TF-IDF + Multiclass Logistic Regression + Data Augmentation



Confusion matrix TF-IDF + Linear SVM



Inference output using SVM model

Positive Review with Emotion Ambiguity (Moderate Confidence)

Κείμενο (απόσπασμα):

"This movie was absolutely amazing! I loved every second of it."

Πρόβλεψη μοντέλου: **surprise**

Confidence: 0.574

Κατανομή πιθανοτήτων (Top):

- surprise: **0.574**
- love: 0.212
- joy: 0.167

Σχόλιο:

Παρότι το κείμενο εκφράζει έντονα θετικό συναίσθημα, το μοντέλο SVM προβλέπει την κλάση *surprise* με μέτρια εμπιστοσύνη. Η σχετικά υψηλή πιθανότητα των κλάσεων *love* και *joy* υποδηλώνει συναισθηματική επικάλυψη μεταξύ θετικών συναισθημάτων, φαινόμενο αναμενόμενο σε σύντομα και ενθουσιώδη κείμενα.

Strong Negative Signal with Very High Confidence

Κείμενο (απόσπασμα):

"I hated this film. It was boring and predictable."

Πρόβλεψη μοντέλου: **sadness**

Confidence: 0.981

Κατανομή πιθανοτήτων (Top):

- sadness: **0.981**
- anger: 0.019
- joy: ≈ 0.0002

Σχόλιο:

Το μοντέλο εμφανίζει εξαιρετικά υψηλή εμπιστοσύνη στην πρόβλεψη, γεγονός που υποδηλώνει σαφές και μονοσήμαντο συναισθηματικό σήμα. Η πολύ μεγάλη απόσταση μεταξύ της επικρατούσας κλάσης και των υπολοίπων πιθανοτήτων καταδεικνύει επιτυχή και σταθερή απόφαση του SVM.

Inference output using SVM model

Emotionally Neutral Text – Low Confidence Prediction

Κείμενο (απόσπασμα):

"I'm not sure how I feel about this movie."

Πρόβλεψη μοντέλου: joy

Confidence: 0.597

Κατανομή πιθανοτήτων (Top):

- joy: 0.597
- surprise: 0.151
- fear: 0.088

Σχόλιο:

Το κείμενο εκφράζει αβεβαιότητα και απουσία ξεκάθαρου συναισθήματος. Η κατανομή πιθανοτήτων δείχνει ότι καμία κλάση δεν κυριαρχεί έντονα, γεγονός που αντικατοπτρίζει τη δυσκολία του μοντέλου να αποδώσει συναίσθημα σε συναισθηματικά ουδέτερα κείμενα.

Mixed Opinion Review – Competing Emotions

Κείμενο (απόσπασμα):

"The acting was okay but the plot was confusing."

Πρόβλεψη μοντέλου: joy

Confidence: 0.469

Κατανομή πιθανοτήτων (Top):

- joy: 0.469
- fear: 0.178
- anger: 0.142

Σχόλιο:

Η χαμηλή εμπιστοσύνη και η σχετικά ισοκαταμελημένη πιθανότητα μεταξύ πολλαπλών κλάσεων υποδηλώνουν συναισθηματική σύγχυση. Το παράδειγμα αναδεικνύει περιορισμό του SVM στη διαχείριση κειμένων με μεικτή ή ήπια συναισθηματική φόρτιση.

Inference output using SVM model

Emotionally Charged Text – High Confidence Wrong Prediction

Κείμενο (απόσπασμα): *don't really know where to start with one of the worst films i have had the displeasure to watch in a very long time....*

Πρόβλεψη μοντέλου: **joy** (id=1)

Confidence: 0.9

Κατανομή πιθανοτήτων (Top):

- joy: 0.900
- sadness: 0.081
- anger: 0.016

Σχόλιο : Το παράδειγμα δείχνει ότι ο classifier είναι υπερβολικά σίγουρος, αφού δίνει λάθος ετικέτα (joy) με πολύ υψηλό confidence (0.90) παρότι το απόσπασμα είναι ξεκάθαρα αρνητικό . Αυτό συνάδει με bias προς την πλειοψηφική κλάση αφού στο inference με svm είναι το μόνο που δεν χρησιμοποιήσαμε augmented dataset. Το αποτέλεσμα είναι ότι οι πιθανότητες εμφανίζονται υψηλές ακόμη και όταν η πρόβλεψη είναι λάθος. Στο repo μας αυτός είναι ο λόγος που χρησιμοποιούμε υψηλότερο threshold confidence.

Inference Output using Multiclass Logistic Regression

Παράδειγμα 1: Correct Prediction & High Confidence

Κείμενο (απόσπασμα):

"i really enjoyed the pilot it was as amazing as i hoped"

Πρόβλεψη μοντέλου: **joy**

Confidence: 0.67

Top classes:

- joy: 0.670
- sadness: 0.117
- fear: 0.080

Σχόλιο:

Το κείμενο περιέχει σαφή θετική αξιολόγηση και εκφράσεις ενθουσιασμού, γεγονός που επιτρέπει στο μοντέλο να αποδώσει σωστά την κατηγορία *joy* με σχετικά υψηλή εμπιστοσύνη. Η σημαντική διαφορά μεταξύ της επικρατούσας κλάσης και των υπολοίπων πιθανοτήτων υποδηλώνει ξεκάθαρο συναισθηματικό σήμα.

Παράδειγμα 2: Low confidence prediction

Κείμενο (απόσπασμα):

"the story ... is a poem ... about solitude and silence ... a wonderful film"

Πρόβλεψη μοντέλου: **love**

Confidence: 0.31

Top classes:

- love: 0.309
- joy: 0.299
- sadness: 0.170

Η πολύ μικρή διαφορά μεταξύ των πιθανοτήτων των κλάσεων *love* και *joy* φανερώνει την δυσκολία διάκρισης συγγενικών συναισθημάτων. Το μοντέλο επιλέγει οριακά την κλάση *love*, γεγονός που υποδηλώνει συναισθηματική επικάλυψη και όχι σαφές λάθος.

Inference Output using Multiclass Logistic Regression

Παράδειγμα 3: Wrong prediction with low confidence

Κείμενο (απόσπασμα):

"i have recently watched this movie twice and i can't seem to understand why the hell the makers made this pile of crap"

Πρόβλεψη μοντέλου: **joy**

Confidence: 0.31

Top classes:

- joy: 0.310
- anger: 0.217
- sadness: 0.213

Σχόλιο:

Η χαμηλή εμπιστοσύνη της πρόβλεψης και η μικρή διαφορά μεταξύ των πιθανοτήτων των τριών επικρατέστερων κλάσεων υποδηλώνουν υψηλή αβεβαιότητα. Το παράδειγμα αυτό αναδεικνύει περιορισμούς του μοντέλου στην αντιμετώπιση έντονων αρνητικών εκφράσεων όταν συνυπάρχουν αφηγηματικά ή ουδέτερα τμήματα κειμένου.

Παράδειγμα 4: Correct prediction but low confidence on negative text

Κείμενο (απόσπασμα):

"this movie is weak ... fake boring senseless ... far from what the video box proclaims"

Πρόβλεψη μοντέλου: **anger**

Confidence: 0.36

Top classes:

- anger: 0.364
- sadness: 0.265
- love: 0.161

Σχόλιο:

Το κείμενο περιέχει έντονα αρνητική κριτική με στοιχεία τόσο θυμού όσο και απογοήτευσης. Η σχετικά χαμηλή εμπιστοσύνη της πρόβλεψης δείχνει ότι το μοντέλο δυσκολεύεται να διαχωρίσει μεταξύ *anger* και *sadness*, κάτι που αποτελεί αναμενόμενο περιορισμό σε πραγματικά, μακροσκελή κείμενα με πολλαπλές συναισθηματικές αποχρώσεις.

Inference Output using XGBOOST + Genre Mapping

Παράδειγμα 1: Strong Negative Sentiment (High Confidence)

- **Απόσπασμα:** *"...offensive piece of trash... violent view of sex... im so enraged..."*
- **Detected Emotion:** **ANGER (86%)**
- **AI Vibe Check (Genre Mapping):** Action / Revenge Thriller
- **Observation:** Το μοντέλο εντόπισε με υψηλή βεβαιότητα λέξεις-κλειδιά όπως "enraged" και "offensive". Η αντιστοίχιση σε "Revenge Thriller" είναι επιτυχής, καθώς αντικατοπτρίζει την επιθετικότητα και την ένταση της κριτικής.

Παράδειγμα 2: Sentiment vs. Content Conflict

- **Απόσπασμα:** *"...slasher flick... resident nut job... killing spree... however there are some good positives... I really liked..."*
- **Detected Emotion:** LOVE (62%)
- **AI Vibe Check (Genre Mapping):** Romantic Drama / Heartwarming
- **Observation:** Ενδιαφέρον παράδοξο. Ο χρήστης περιγράφει ταινία τρόμου (slasher), αλλά εκφράζει απόλαυση ("really liked"). Το μοντέλο σωστά αγνόησε το είδος της ταινίας και εντόπισε το θετικό συναίσθημα του θεατή.

Qualitative Analysis – Limitations & Errors

Παράδειγμα 3: Failed Detection in Comedy (Low Confidence)

- **Απόσπασμα:** "...side splitting comedy... belly laughing through the film... annoying some people..."
- **Detected Emotion:** SADNESS (22%)
- **AI Vibe Check (Genre Mapping):** Tearjerker / Heavy Drama
- **Observation:** Σημαντική αστοχία. Παρόλο που υπάρχουν ισχυρές λέξεις χαράς ("laughing", "comedy"), το μοντέλο έδωσε λανθασμένη πρόβλεψη με πολύ χαμηλή βεβαιότητα (Uncertain). Αυτό οδήγησε και το Vibe Check σε αποτυχία (Drama αντί για Comedy).

Παράδειγμα 4: The "Uncertain" Bias

- **Απόσπασμα:** "...some things i will never understand... approach this film expecting an actual movie..."
- **Detected Emotion:** SADNESS (21%)
- **AI Vibe Check (Genre Mapping):** Tearjerker / Heavy Drama
- **Observation:** Το μοντέλο δείχνει αδυναμία όταν το κείμενο είναι σαρκαστικό ή μπερδεμένο. Το χαμηλό σκορ (21%) υποδεικνύει ότι το XGBoost δεν βρήκε ξεκάθαρο μοτίβο και κατέληξε στην "default" ασφαλή επιλογή του Sadness.