

Movie Review Emotion Classifier

Ομάδα συνεργατών : Θεωδωρής Γρηγορίου , Νίκος Μάριος Σπυρόπουλος,
Μιχάλης Μυκωνιάτης

ΠΕΡΙΕΧΟΜΕΝΑ

1.Εισαγωγή	2
2.Περιγραφή δεδομένων	2
3.Προεπεξεργασία δεδομένων	3
4. Εξερευνητική Ανάλυση Δεδομένων (EDA)	4
5. Εξαγωγή Χαρακτηριστικών (Feature Extraction)	8
6. Data Augmentation	12
7.MONTELA ML	13
8 INFERENCE	24
9 Βιβλιογραφία	26

1.Εισαγωγή

Η ταξινόμηση συναισθήματος από γραπτό κείμενο αποτελεί ένα από τα βασικά στοιχεία της Επεξεργασίας Φυσικής Γλώσσας (NLP) καθώς έχει εφαρμογή σε τομείς όπως η ανάλυση συναισθήματος λόγου σε κοινωνικά δίκτυα, η κατηγοριοποίηση γνώμης και η υποστήριξη συστημάτων αλληλεπίδρασης ανθρώπου-υπολογιστή (chatbots). Στο πλαίσιο αυτό, η εργασία αυτή εξετάζει την πολυταξική ταξινόμηση συναισθήματος σε σύντομα κείμενα.

Στόχος της εργασίας είναι η ανάπτυξη και αξιολόγηση μοντέλων μηχανικής μάθησης για την κατηγοριοποίηση κειμένων σε έξι κατηγορίες συναισθήματος: sadness, joy, love, anger, fear και surprise. Ιδιαίτερη έμφαση δίνουμε στην μελέτη και έρευνα όλου του κύκλου εργασίας ενός συστήματος μηχανικής μάθησης και λιγότερο στην τελική επίδοση των μοντέλων.

Ο τρόπος με τον οποίο προσεγγίσαμε το πρόβλημα ταιριάζει με αυτά που διδαχθήκαμε στο μάθημα της μηχανικής μάθησης καθώς περιλαμβάνει εξερευνητική ανάλυση δεδομένων, προεπεξεργασία δεδομένων (κειμένου), εκπαίδευση πολλών μοντέλων και αξιολόγηση και έπειτα σύγκριση των αποτελεσμάτων.

Ο σκοπός δεν είναι η επίτευξη της μέγιστης δυνατής ακρίβειας, αλλά η κατανόηση των πλεονεκτημάτων και περιορισμών διαφορετικών προσεγγίσεων στην κατηγοριοποίηση συναισθήματος.

2.Περιγραφή δεδομένων

2.1 DATASET

Για την εργασία χρησιμοποιήθηκε το σύνολο δεδομένων `dair-ai/emotion`. Το σύνολο δεδομένων είναι διαθέσιμο μέσω της πλατφόρμας του Hugging Face Datasets και περιλαμβάνει σύντομα σχόλια χρηστών από μέσα κοινωνικής δικτύωσης, τα οποία είναι Labeled με έξι κατηγορίες συναισθήματος: `sadness`, `joy`, `love`, `anger`, `fear`, `surprise`.

Το συγκεκριμένο dataset επιλέχθηκε καθώς μας καλύπτει για το πρόβλημα του `multilabel classification`, περιλαμβάνει σύντομα και θορυβώδη κείμενα και παρουσιάζει ανισορροπία κλάσεων, γεγονός που το καθιστά κατάλληλο για τη μελέτη πρακτικών ζητημάτων μηχανικής μάθησης.

Το dataset χωρίζεται ήδη σε `train set` και `test set`

- Σύνολο `train set`: 16000 samples
- Σύνολο `test set`: 2000 samples
- Class labels : 6

2.2 Φόρτωση και οργάνωση δεδομένων

Η φόρτωση των δεδομένων έγινε μέσω της βιβλιοθήκης `datasets` της HuggingFace. Κατά τη φόρτωση, τα δεδομένα μετατράπηκαν σε δομές τύπου `pandas.DataFrame` για ευκολότερη επεξεργασία και ανάλυση.

Έπειτα τα δεδομένα αποθηκεύτηκαν τοπικά σε μορφή αρχείων `CSV` (`train/test`), επιτρέποντας έτσι την επαναχρησιμοποίηση των δεδομένων χωρίς επαναφόρτωση αλλά και τον καθαρό διαχωρισμό μεταξύ αρχικών και επεξεργασμένων δεδομένων.

2.3 Δομή και χαρακτηριστικά των δεδομένων

Κάθε δείγμα του dataset αποτελείται από:

- Γραπτό κείμενο (`text`)
- Μια ετικέτα (`label`), η οποία αντιστοιχεί σε μία από τις έξι κατηγορίες συναισθήματος

Για τις ανάγκες της ανάλυσης και της προεπεξεργασίας, δημιουργήθηκαν επιπλέον χαρακτηριστικά (`feature engineering`) όπως:

- Μήκος κειμένου σε χαρακτήρες
- Αριθμός λέξεων στο αρχικό αλλά και στο `cleaned` κείμενο

Τα πρόσθετα αυτά χαρακτηριστικά χρησιμοποιήθηκαν για σκοπούς εξερευνητικής ανάλυσης δεδομένων και δεν επηρέασαν στην εκπαίδευση των μετέπειτα μοντέλων

2.4 Σχόλια για την ποιότητα των δεδομένων

Το `dair-ai/emotion` αποτελεί ένα ήδη προεπεξεργασμένο και καθαρό dataset, χωρίς έντονο θόρυβο όπως URL, emojis ή ειδικούς χαρακτήρες.

3. Προεπεξεργασία δεδομένων

Παρότι το σύνολο δεδομένων που χρησιμοποιούμε είναι ήδη καθαρισμένο, υλοποιήθηκε πλήρης διαδικασία προεπεξεργασίας κειμένου για ακαδημαϊκούς σκοπούς αλλά και σε περίπτωση που χρησιμοποιούσαμε κάποιο άλλο dataset το οποίο δεν θα ήταν ήδη `preprocessed`.

Η διαδικασία προεπεξεργασίας εφαρμόστηκε με ενιαίο τρόπο σε όλα τα δεδομένα και περιλάμβανε τα εξής βήματα:

- Μετατροπή όλων των χαρακτήρων σε πεζά γράμματα
- Αφαίρεση URLs και αναφορών χρηστών (“@”)
- Αφαίρεση μη αλφαβητικών χαρακτήρων
- Κανονικοποίηση κενών χαρακτήρων

Η επιλογή αφαίρεσης των παραπάνω θεωρείται καθαρισμός δεδομένων κειμένου καθώς με την αφαίρεση τους και τα δεδομένα μικραίνουν σε μέγεθος αλλά και δεν επηρεάζει καθόλου την εκπαίδευση των μοντέλων καθώς αυτοί οι χαρακτήρες έχουν μηδενικό βάρος ως προς το `label` του συναισθήματος.

Μετά τον καθαρισμό, υπολογίζουμε και ένα επιπλέον βοηθητικό χαρακτηριστικό, το `clean_word_len` το οποίο είναι ο αριθμός των λέξεων μετά την προεπεξεργασία. Στο `dair-ai` σχεδόν όλα είχαν το ίδιο μέγεθος αλλά σε άλλα dataset τα οποία δεν είναι ήδη `preprocessed` η διαφορά θα είναι αισθητή.


4. Εξερευνητική Ανάλυση Δεδομένων (EDA)

Η εξερευνητική ανάλυση δεδομένων πραγματοποιήθηκε στο `train set` με στόχο την κατανόηση της δομής, των ιδιοτήτων και των σχέσεων των δεδομένων.

4.1 Κατανομή Κλάσεων Συναισθημάτων

Η κατανομή των κλάσεων συναισθημάτων στο `train set` αποτελεί ένα πολύ βασικό στοιχείο της ανάλυσης. Όπως φαίνεται στο παρακάτω γράφημα, το dataset παρουσιάζει έντονη ανισορροπία μεταξύ των κλάσεων (`class imbalance`), με τα συναισθήματα `Joy` και `Sadness` να εμφανίζονται σημαντικά συχνότερα σε σχέση με τις υπόλοιπες κατηγορίες, ενώ το `surprise` αποτελεί την

λιγότερο εμφανιζόμενη κλάση.



Σχήμα 1: Κατανομή των κλάσεων συναισθήματος στο train set του *dair-ai/emotion*. Output from *analysis.ipynb*


Η ανισορροπία αυτή αποτελεί κρίσιμο στοιχείο για την μετέπειτα αξιολόγηση των μοντέλων, καθώς η χρήση της μετρικής *accuracy* μπορεί να οδηγήσει σε παραπλανητικά συμπεράσματα. Για τον λόγο αυτό, στα επόμενα στάδια της εργασίας δίνεται έμφαση και σε άλλες μετρικές όπως το *macro-averaged F1-score*, οι οποίες αποδίδουν ίσο βάρος σε όλες τις κλάσεις.

Το *F1-score* αποτελεί τον αρμονικό μέσο της ακρίβειας (*precision*) και της ανάκλησης (*recall*) και παρέχει ένα ισορροπημένο μέτρο απόδοσης.

Το *Macro-averaged F1-score* υπολογίζεται ως ο μέσος όρος του *F1-score* σε όλες τις κλάσεις, αποδίδοντας ίσο βάρος σε κάθε κατηγορία συναισθήματος ανεξάρτητα από το πλήθος των δειγμάτων της. Έτσι αποφεύγεται η υπερεκτίμηση της απόδοσης σε πλειοψηφικές κλάσεις και παρέχεται μια πιο αντιπροσωπευτική εικόνα της συνολικής συμπεριφοράς του μοντέλου σε τέτοιες συνθήκες ανισορροπίας κλάσεων.

4.2 Ανάλυση μήκους κειμένων

Εξετάστηκε επίσης το μήκος των κειμένων μετά την προεπεξεργασία, με βάση τον αριθμό λέξεων ανά δείγμα (clean_word_len).




Σχήμα 2: Κατανομή του αριθμού λέξεων ανά κείμενο μετά την προεπεξεργασία, η οποία αναδεικνύει το μέγεθος αυτών

Όπως φαίνεται στο παραπάνω ιστόγραμμα, η πλειονότητα των κειμένων αποτελείται από μικρό αριθμό λέξεων, με τα περισσότερα δείγματα να περιέχουν λιγότερες από 20 λέξεις. Η πληροφορία λοιπόν που σχετίζεται με το συναίσθημα βρίσκεται συμπυκνωμένη σε λίγες λέξεις. Θα δούμε παρακάτω πως αυτή η παρατήρηση μας οδηγεί στο να κάνουμε μια συγκεκριμένη επιλογή μεθόδου εξαγωγής χαρακτηριστικών.

4.3 Μήκος Κειμένων ανα Κατηγορία Συναισθήματος

Εξετάστηκε επίσης, η κατανομή του μήκους των κειμένων ανα κατηγορία συναισθήματος με βάση τον αριθμό των λέξεων μετά την προεπεξεργασία




Σχήμα 3: Κατανομή του μήκους των κειμένων ανά κατηγορία συναισθήματος στο train set

Όπως φαίνεται στο παραπάνω boxplot, το μήκος κειμένων παρουσιάζει παρόμοια κατανομή σε όλες τις κατηγορίες συναισθήματος. Δεν παρατηρούνται σημαντικές αποκλίσεις ούτε στο μέσο μήκος, ούτε στη διασπορά των κειμένων ανά συναισθήμα. Με την παρατήρηση αυτή μπορούμε να συμπεράνουμε ότι το μήκος κειμένου από μόνο του δεν αποτελεί επαρκές χαρακτηριστικό για την κατηγοριοποίηση συναισθήματος και ότι η πληροφορία διαφοροποίησης βρίσκεται κυρίως στο λεξιλόγιο και όχι στο πλήθος των λέξεων. Το συμπέρασμα αυτό μας οδηγεί στην ανάγκη αξιοποίησης χαρακτηριστικών που αποτυπώνουν τη χρήση και τη σημασία των λέξεων, όπως παρουσιάζεται στο επόμενο κεφάλαιο.


4.4 Συχνότερες λέξεις ανά Label συναισθήματος

Ένα ακόμη πράγμα το οποίο αναζητήσαμε είναι οι λέξεις που εμφανίζονται συχνότερα ανά κατηγορία συναισθήματος



Σχήμα 4: Barplot με τις συχνότερα εμφανιζόμενες λέξεις για κάθε συναίσθημα

Κάτι το οποίο φαίνεται με μια πρώτη ματιά, είναι ότι για κάθε συναίσθημα οι συχνότερα εμφανιζόμενες λέξεις είναι οι ίδιες. Αυτό συμβαίνει καθώς όλες οι λέξεις είναι stopwords και επηρεάζουν μηδενικά το συναίσθημα του κειμένου. Για τον λόγο αυτό αφαιρέσαμε έπειτα από διάφορες δοκιμές τις πρώτες 60 συχνότερες λέξεις για κάθε κατηγορία και καταλήξαμε στο παρακάτω.



Σχήμα 5: Barplot με τις 60 και μετά συχνότερες λέξεις για κάθε συναίσθημα

Η διαφορά εδώ είναι ξεκάθαρη. Το παραπάνω γράφημα αποκαλύπτει λεξικά μοτίβα που σχετίζονται με το κάθε συναίσθημα καθώς παρατηρούνται λέξεις με μεγαλύτερη σημασιολογική συνάφεια, οι οποίες διαφοροποιούν τις κατηγορίες συναισθήματος των κειμένων. Άλλο ένα στοιχείο το οποίο φανερώνει ότι η πληροφορία βρίσκεται στο λεξιλόγιο και όχι στις γενικές λειτουργικές λέξεις και το πλήθος αυτών.

5. Εξαγωγή Χαρακτηριστικών (Feature Extraction)

Η εξαγωγή χαρακτηριστικών αποτελεί ένα από τα πιο κρίσιμα στάδια της διαδικασίας, καθώς μετατρέπει τα δεδομένα που βρίσκονται σε μορφή κειμένου σε αριθμητικές αναπαραστάσεις (διανύσματα). Η μετατροπή αυτή είναι απαραίτητη, καθώς τα μοντέλα μηχανικής μάθησης δεν μπορούν να επεξεργαστούν απευθείας δεδομένα κειμένου, αλλά βασίζονται αποκλειστικά σε αριθμητική πληροφορία. Η αριθμητική αυτή αναπαράσταση προκύπτει μέσω διαφορετικών μεθόδων εξαγωγής χαρακτηριστικών, οι οποίες αποτυπώνουν τη σημασία και τη χρήση των λέξεων μέσα στα κείμενα. Στις επόμενες ενότητες παρουσιάζονται και αναλύονται οι μέθοδοι που χρησιμοποιήθηκαν στην παρούσα εργασία.

5.1 TF IDF (Term Frequency - Inverse Document Frequency)

Η πρώτη μέθοδος που χρησιμοποιήθηκε για εξαγωγή χαρακτηριστικών είναι η TF-IDF. Η μέθοδος αυτή παρέχει έναν απλό αλλά αποτελεσματικό τρόπο ποσοτικοποίησης της σημασίας των λέξεων μέσα στα κείμενα.

Η βασική ιδέα είναι ότι μία λέξη είναι σημαντική για ένα συγκεκριμένο κείμενο όταν εμφανίζεται συχνά σε αυτό, αλλά όχι συχνά στο σύνολο όλων των κειμένων.

Ο όρος Term Frequency (TF) αποτυπώνει πόσο συχνά εμφανίζεται μια λέξη μέσα σε ένα συγκεκριμένο κείμενο.

$$TF(t) = \frac{\text{number of times term } t \text{ appears in a document}}{\text{total number of terms in the document}}$$

Ενώ ο όρος Inverse Document Frequency (IDF) μειώνει το βάρος των λέξεων που εμφανίζονται σε πολλά διαφορετικά κείμενα.

$$IDF(t) = \text{Log}\left(\frac{\text{number of documents}}{\text{number of documents containing term } t}\right)$$

Επομένως προκύπτει το TF-IDF κάθε λέξης από το γινόμενο των δύο παραπάνω όρων:

$$TF - IDF(t) = TF(t) \times IDF(t)$$

Το αποτέλεσμα λοιπόν είναι να αποδίδεται χαμηλό βάρος σε λέξεις που είναι πολύ συχνές σε όλα τα κείμενα, ενώ ενισχύει λέξεις που είναι περισσότερο χαρακτηριστικές για συγκεκριμένα κείμενα. Η λογική αυτή συμβαδίζει άμεσα με τις παρατηρήσεις που έγιναν στο EDA καθώς καταλήξαμε στο ότι οι κοινές λέξεις δεν συμβάλλουν ουσιαστικά στην διάκριση των συναισθημάτων.

Πρακτικά, κάθε κείμενο αναπαρίσταται ως ένα διάνυσμα, στο οποίο κάθε θέση αντιστοιχεί σε μία λέξη του λεξιλογίου και η τιμή της λέξης δίνεται από το αντίστοιχο TF-IDF βάρος. Με τον τρόπο αυτό, τα κείμενα μετατρέπονται σε αριθμητικές αναπαραστάσεις που μπορούν να χρησιμοποιηθούν απευθείας από μοντέλα μηχανικής μάθησης.

Μια σημαντική παρατήρηση είναι πως χρησιμοποιήσαμε τόσο unigrams όσο και bigrams. Τα unigrams είναι μεμονωμένες λέξεις των οποίων τα βάρη προκύπτουν όπως παραπάνω ενώ τα bigrams είναι δυάδες λέξεων. Δώσαμε την επιλογή των ζευγαριών καθώς έτσι το μοντέλο μπορεί να αποτυπώσει απλές φραστικές δομές που συχνά μεταφέρουν εντονότερη ή διαφορετική πληροφορία σε σχέση με τις μεμονωμένες λέξεις (πχ “not good”, “very happy”, “not sure”).

5.2 GLOVE WORD EMBEDDINGS

5.2.1 Notebook for downloading Stanford's library and intuition

Η δεύτερη μέθοδος που χρησιμοποιήθηκε για εξαγωγή χαρακτηριστικών είναι το GloVe (Global Vectors for Word Representation). Αρχικά, στα notebooks χρησιμοποιούμε ένα παράδειγμα υλοποίησης από την ιστοσελίδα [geogff.org/geogff/](https://www.geogff.org/geogff/) ώστε παραθέτοντας μια απλή εφαρμογή όποιος κατεβάσει το `repo` να είναι σε θέση να έχει μια διαίσθηση σχετικά με τον τρόπο με τον οποίο λειτουργεί το `glove`. Πιο συγκεκριμένα, προσέγγιση του GloVe συνδυάζει την παγκόσμια στατιστική πληροφορία με την τοπική πληροφορία συμφραζομένων που συναντάμε σε μοντέλα τύπου Word2Vec, ώστε λέξεις που εμφανίζονται σε παρόμοια πλαίσια να αποκτούν παρόμοια διανύσματα. Για να το πετύχει αυτό, κατασκευάζει έναν πίνακα συν-εμφάνισης (*co-occurrence matrix*) όπου μετρά πόσο συχνά δύο λέξεις εμφανίζονται κοντά η μία στην άλλη μέσα σε ένα παράθυρο συμφραζομένων και στη συνέχεια εκπαιδεύει τα διανύσματα έτσι ώστε το εσωτερικό γινόμενο (*dot product*) δύο διανυσμάτων να προσεγγίζει την πληροφορία συν-εμφάνισης του αντίστοιχου ζεύγους λέξεων. Η σημασία του προαναφερθέντος notebook δεν περιορίζεται μόνο σε αυτό αλλά κατεβάζει, τρέχοντάς το, το GloVe dataset από το NLP repository του Stanford και συγκεκριμένα ένα φάκελο που περιέχει τα modules της TensorFlow/Keras (και το NumPy) που χρειάζονται για να μετατραπεί το κείμενο σε αριθμούς και να κατασκευαστεί ο πίνακας *embeddings* από τα προεκπαιδευμένα GloVe διανύσματα.

5.2.2 Python script for machine learning implementation

Αρχικά, με το `Tokenizer` της Keras φτιάχνουμε λεξιλόγιο από τα *training* κείμενα και μετατρέπουμε τις λέξεις σε ακέραια *ids*, ενώ με το `oov_token="<UNK>"` χειριζόμαστε λέξεις που δεν υπάρχουν στο λεξιλόγιο βάζοντάς τις σε ειδικό *token*. Στη συνέχεια, διαβάζουμε το `glove.6B.100d.txt` και χτίζουμε την *embedding matrix*, δηλαδή έναν πίνακα που αντιστοιχίζει κάθε *id* λέξης στο αντίστοιχο GloVe διάνυσμα (ό,τι δεν βρεθεί μένει μηδενικό).

Μετά μετατρέπουμε τα κείμενα σε ακολουθίες *ids* και εφαρμόζουμε `pad_sequences` ώστε όλες οι ακολουθίες να έχουν κοινό μήκος `max_len` και να γίνουν ένας ενιαίος πίνακας εισόδου. Τέλος, το πιο κρίσιμο βήμα είναι η `sequences_to_vectors`: χωρίς αυτήν δεν θα μπορούσαμε να τρέξουμε κλασικούς αλγορίθμους *machine learning* (π.χ. *Logistic Regression*, *SVM*), γιατί χρειαζόμαστε για κάθε κείμενο ένα σταθερού μήκους διάνυσμα χαρακτηριστικών και όχι μια μεταβλητού μήκους ακολουθία. Για αυτό κάνουμε *pooling* πάνω στα *word embeddings* (*mean* και *max*) και τα ενώνουμε, ώστε κάθε κείμενο να εκπροσωπείται ως ένα «*feature vector*» έτοιμο για τους ταξινομητές μας.

5.2.3* ΠΑΡΑΡΤΗΜΑ

Τρέξαμε όλους τους κλασικούς ML ταξινομητές μας πάνω σε χαρακτηριστικά που προκύπτουν από GloVe *embeddings* και παρατηρήσαμε ότι οι επιδόσεις κινούνται περίπου στο 30%–60%, κάτι που είναι λογικό γιατί το GloVe είναι στατικό *embedding* (ίδιο διάνυσμα για μια λέξη ανεξάρτητα από τα συμφραζόμενα) και όταν το συμπυκνώνουμε σε ένα μόνο διάνυσμα ανά κείμενο με *pooling* χάνουμε πληροφορία για σειρά λέξεων, άρνηση και λεπτές αλληλεπιδράσεις

που συχνά είναι κρίσιμες στην ταξινόμηση. Μέσα σε αυτό το πλαίσιο, το XGBoost είναι το μόνο που μας δίνει αισθητά καλύτερα αποτελέσματα, επειδή ως boosted δέντρα μπορεί να «πιάσει» μη γραμμικές σχέσεις και αλληλεπιδράσεις ανάμεσα στα χαρακτηριστικά του διανύσματος (mean/max από τις διαστάσεις των embeddings) πιο αποτελεσματικά από γραμμικά μοντέλα όπως Logistic Regression ή Linear SVM και για αυτό το λόγο συμπεριλάβαμε XGBoost με GloVe στα μοντέλα που εκπαιδεύτηκαν.

5.3 Word2Vec Embeddings

Η τρίτη μέθοδος που χρησιμοποιήσαμε για την εξαγωγή χαρακτηριστικών είναι το Word2Vec. Σε αντίθεση με το GloVe που βασίζεται σε global statistics (πίνακες συν-εμφάνισης), το Word2Vec είναι ένα νευρωνικό δίκτυο που μαθαίνει διανυσματικές αναπαραστάσεις λέξεων προβλέποντας το context (γειτονικές λέξεις) για κάθε λέξη-στόχο.

Για την υλοποίηση χρησιμοποιήσαμε τη βιβλιοθήκη **gensim**. Ωστόσο, προχωρήσαμε σε δύο σημαντικές βελτιώσεις (tuning) σε σχέση με την τυπική υλοποίηση, ώστε να προσαρμόσουμε το μοντέλο στις ανάγκες του δικού μας dataset:

1. **Tuning Παραμέτρων:** Ενώ η default διάσταση των διανυσμάτων είναι συνήθως 100, παρατηρήσαμε ότι για το συγκεκριμένο πρόβλημα ταξινόμησης, η αύξηση της διάστασης του διανύσματος (vector size) στο **300** και η αύξηση των εποχών εκπαίδευσης (epochs) σε **50**, οδήγησε σε σημαντικά καλύτερη αναπαράσταση των σημασιολογικών σχέσεων μεταξύ των λέξεων.
2. **Concatenation Mean & Max Pooling (Η βασική μας τροποποίηση):** Το Word2Vec παράγει ένα διάνυσμα για *κάθε λέξη*. Για να ταξινομήσουμε *ολόκληρο το κείμενο* (sentence classification), η πιο κοινή πρακτική είναι να πάρουμε τον μέσο όρο (Mean) των διανυσμάτων των λέξεων του κειμένου. Ωστόσο, παρατηρήσαμε ότι ο απλός μέσος όρος τείνει να "εξομαλύνει" την πληροφορία, χάνοντας έντονες λέξεις-κλειδιά που καθορίζουν το συναίσθημα (π.χ. η λέξη "hate" σε μια μεγάλη πρόταση). Για να το αντιμετωπίσουμε αυτό, υλοποιήσαμε μια custom συνάρτηση (get_mean_vectors) η οποία για κάθε κείμενο υπολογίζει δύο διανύσματα:
 - **Mean Vector:** Το μέσο όρο των διανυσμάτων (γενικό νόημα).
 - **Max Vector:** Τη μέγιστη τιμή σε κάθε διάσταση (εντοπίζει τα πιο έντονα χαρακτηριστικά). Τελικά, συνενώνουμε (concatenate) αυτά τα δύο, δημιουργώντας ένα διάνυσμα διπλάσιου μεγέθους που περιέχει τόσο τη γενική πληροφορία όσο και τις κορυφώσεις (peaks) του συναισθήματος.

6. Data Augmentation

Η διαδικασία αυτή εφαρμόστηκε αποκλειστικά στο training set. Σκοπός αυτής, είναι η δημιουργία παραλλαγών των υπάρχοντων κειμένων μέσω συνωνύμων και μικρών μετασχηματισμών αλλά και η ενίσχυση των μειοψηφικών κλάσεων.

6.1 Στρατηγική

Η διαδικασία βασίστηκε σε ήπιες τεχνικές μετασχηματισμού κειμένου τύπου EDA (Easy Data Augmentation), με στόχο τη δημιουργία νέων παραδειγμάτων που διατηρούν το αρχικό συναισθηματικό περιεχόμενο. Συγκεκριμένα, αντικαταστήσαμε λέξεις με συνώνυμες αυτών με ιδιαίτερη προσοχή στο να μην αλλάξει το label συναισθήματος. Για τον λόγο αυτό εξαιρέθηκαν από τη διαδικασία αντικατάστασης λέξεις που σχετίζονται άμεσα με το συναίσθημα, καθώς και εκφράσεις άρνησης, ώστε να μειωθεί ο κίνδυνος αλλοίωσης του κειμένου.

6.2 Ελεγχόμενη ενίσχυση και αναπαραγωγή

Η ενίσχυση αυτή των δεδομένων πραγματοποιήθηκε ελεγχόμενα, λαμβάνοντας υπόψη το μήκος του κειμένου και τη δυνατότητα παραγωγής έγκυρων παραλλαγών. Πολύ σύντομα κείμενα εξαιρέθηκαν από την διαδικασία ($\text{num_words} \leq 2$), καθώς οι μετασχηματισμοί σε τέτοιες περιπτώσεις θα ήταν παραπλανητικοί και χωρίς ουσία.

Επιπλέον, χρησιμοποιήθηκε σταθερό random seed ώστε η διαδικασία να παράγει συνεπή αποτελέσματα σε επαναλαμβανόμενες εκτελέσεις, διευκολύνοντας τη σύγκριση πειραμάτων.

6.3 Class Balance - Augmentation

Πέρα από την λεξική ενίσχυση, εφαρμόστηκε και στοχευμένη εξισορρόπηση κλάσεων. Οι μειοψηφικές κλάσεις εμπλουτίστηκαν με επιπλέον παραδείγματα έως ότου προσεγγίσουν το πλήθος δειγμάτων της “μεγαλύτερης” κλάσης. Η διαδικασία αυτή επιτρέπει τη δημιουργία ενός πιο ισορροπημένου συνόλου εκπαίδευσης, χωρίς την αφαίρεση πραγματικών δεδομένων από τις πλειοψηφικές κατηγορίες.

Η τελική μορφή του train set περιλαμβάνει τόσο τα αρχικά όσο και τα εμπλουτισμένα δείγματα, τα οποία κατανέμονται τυχαία ώστε να αποφεύγεται η δημιουργία συσχετισμών μεταξύ της σειράς των δεδομένων και της προέλευσής τους.

6.4 Χρήση του augmented dataset

Στη συνέχεια παρουσιάζονται τα μοντέλα μηχανικής μάθησης που εφαρμόστηκαν, τα οποία εκπαιδεύτηκαν τόσο στο αρχικό όσο και στο εμπλουτισμένο σύνολο δεδομένων. Η σύγκριση των αποτελεσμάτων πριν και μετά το data augmentation επιτρέπει την αξιολόγηση της συμβολής του εμπλουτισμού στην απόδοση και τη γενίκευση των ταξινομητών.


7. MONTEΛΑ ML

7.1. SVM TRAINING

7.1.1 SVM THEORY AND EXPERIMENTATIONS IN NOTEBOOK

Ο SVM (Support Vector Machine) είναι ένας επιβλεπόμενος ταξινομητής που, δεδομένων των διανυσμάτων χαρακτηριστικών X , προσπαθεί να βρει ένα υπερεπίπεδο απόφασης που χωρίζει όσο γίνεται καλύτερα τις κλάσεις, μεγιστοποιώντας το περιθώριο (margin), δηλαδή την απόσταση του υπερεπίπεδου από τα κοντινότερα σημεία των κλάσεων (support vectors). Στην πράξη αυτό το μεγάλο margin λειτουργεί σαν μορφή regularization και συχνά βοηθά τη γενίκευση σε νέα δεδομένα, ειδικά όταν έχουμε πολλά χαρακτηριστικά όπως στα TF-IDF. Στον κώδικά μας χρησιμοποιούμε γραμμικό SVM είτε ως SVC(kernel="linear") είτε ως LinearSVC, που και τα δύο στοχεύουν σε γραμμικό διαχωρισμό, αλλά υλοποιούνται διαφορετικά (libsvm vs liblinear) και διαφέρουν στον τρόπο ταξινόμησης/βελτιστοποίησης, γι' αυτό μπορεί να δίνουν λίγο διαφορετικές επιδόσεις και χρόνους εκπαίδευσης. Η χρήση και των δύο έγινε στο pipeline, μια για το tfidf και μια για το Word 2 Vec καθαρά για λόγους εξοικείωσης με τις διαφορετικές εκδόσεις, ενώ και SVM με rbf kernel υπάρχει στο πεδίο notebooks για τον ίδιο λόγο (δεν χρησιμοποιείται στο μοντέλο γιατί είναι ελαφρώς χειρότερο). Η παράμετρος C ελέγχει το trade-off ανάμεσα σε μεγαλύτερο margin και λιγότερα σφάλματα στο training: όσο μεγαλύτερο C τόσο περισσότερη έμφαση έχουν τα σφάλματα (λιγότερη κανονικοποίηση), ενώ μικρότερο C επιτρέπει πιο μεγάλο περιθώριο για καλύτερη γενίκευση. Επιπλέον, με class_weight="balanced" προσαρμόζουμε τα βάρη των κλάσεων αντιστρόφως ανάλογα με τη συχνότητά τους, ώστε ο SVM να μην ευνοεί υπερβολικά τις πολυπληθείς κλάσεις όταν υπάρχει ανισορροπία στο dataset.

Στο notebook υλοποιούμε ένα πλήρες baseline ταξινόμησης συναισθήματος με TF-IDF και SVM: αρχικά φορτώνουμε τα δεδομένα και κάνουμε προεπεξεργασία, έπειτα εκπαιδεύουμε έναν TfidfVectorizer πάνω στο training set ώστε να μετατρέψουμε τα κείμενα σε αριθμητικά χαρακτηριστικά TF-IDF (αραιός πίνακας χαρακτηριστικών) και χρησιμοποιούμε τον ίδιο vectorizer για να κάνουμε transform στο test set. Στη συνέχεια κάνουμε αναζήτηση υπερπαραμέτρου για το SVM δοκιμάζοντας διαφορετικές τιμές του C και αξιολογώντας τις με 5-fold StratifiedKFold cross-validation, ώστε κάθε fold να κρατά παρόμοια κατανομή κλάσεων, και επιλέγουμε την τιμή που δίνει τον καλύτερο μέσο όρο score. Με βάση αυτό επιλέγουμε την τιμή $C=10.0$, την οποία χρησιμοποιούμε και σαν παράμετρο στο γραμμικό SVM και στην συνέχεια εκπαιδεύουμε το τελικό μοντέλο SVC με RBF kernel, ενεργοποιούμε class_weight='balanced' για να αντιμετωπίσουμε πιθανή ανισορροπία κλάσεων (δίνοντας μεγαλύτερο βάρος στις πιο σπάνιες κλάσεις) και probability=True για να μπορούμε να πάρουμε πιθανότητες πρόβλεψης. Τέλος, αξιολογούμε στο test set με accuracy και F1 (weighted/macro/micro), υπολογίζουμε μετρικές ανά κλάση (precision/recall/F1), και οπτικοποιούμε την απόδοση με confusion matrix και bar plot των F1-scores ανά συναίσθημα για να δούμε σε ποιες κατηγορίες αποδίδει καλύτερα ή χειρότερα το μοντέλο.



Σχήμα 6: F1-score for SVM classifier with TF-IDF with C=10.0.

7.1.2 LINEAR SVM PIPELINE

Στο παραπάνω script υλοποιούμε ένα ενιαίο pipeline πειραμάτων όπου κρατάμε σταθερό τον ταξινομητή (SVM) και αλλάζουμε την αναπαράσταση του κειμένου (TF-IDF, Word2Vec, GloVe), ώστε να συγκρίνουμε δίκαια εναλλακτικούς τρόπους εξαγωγής χαρακτηριστικών. Στη ροή TF-IDF εκπαιδεύουμε τον TF-IDF vectorizer μόνο στο training set και μετασχηματίζουμε το test set στον ίδιο χώρο χαρακτηριστικών, και στη συνέχεια εκπαιδεύουμε γραμμικό SVM με `SVC(kernel="linear")`, χρησιμοποιώντας `class_weight="balanced"` για να δοθεί μεγαλύτερη ποιότητα στα λάθη των μειοψηφικών κλάσεων, αφού στη scikit-learn το `balanced` ορίζει βάρη αντιστρόφως ανάλογα με τις συχνότητες των κλάσεων. Παράλληλα, υλοποιούμε ροή TF-IDF + augmentation(balanced augmented training) και ξαναεκπαιδεύουμε TF-IDF και SVM πάνω σε αυτό. Σε αυτή την balanced-augmented περίπτωση είναι λογικό να μην χρησιμοποιούμε `class_weight="balanced"`, γιατί έχουμε ήδη επέμβει στην κατανομή κλάσεων μέσω εξισορρόπησης και η επιπλέον στάθμιση θα διπλομετρήσει την ίδια διόρθωση, αλλάζοντας πρακτικά το αποτελεσματικό C ανά κλάση και ενδέχεται να οδηγήσει σε υπερ-αντιστάθμιση υπέρ των κλάσεων που ήταν αρχικά μειοψηφικές.

Για τις πυκνές αναπαραστάσεις, ακολουθούμε δύο αντίστοιχες διαδρομές με Word2Vec και GloVe: μετατρέπουμε τα κείμενα σε ακολουθίες token ids, εφαρμόζουμε padding σε σταθερό μήκος και κάνουμε pooling πάνω στα word embeddings (mean+max) ώστε κάθε κείμενο να γίνει ένα σταθερού μήκους διάνυσμα κατάλληλο για κλασικούς ταξινομητές. Επειδή ο SVM είναι ευαίσθητος στην κλίμακα των χαρακτηριστικών, πριν την εκπαίδευση εφαρμόζουμε StandardScaler (fit μόνο στο train, transform στο test) για να τυποποιήσουμε τα dense διανύσματα και να έχουμε πιο σταθερή εκπαίδευση/βελτιστοποίηση. Όπως και πριν, εξετάζουμε τόσο non-augmented όσο και augmented εκδοχές για Word2Vec, ενώ στο GloVe τρέχουμε μόνο

την augmented εκδοχή κυρίως για να δοκιμάσουμε/επιβεβαιώσουμε το pipeline , επειδή η non-augmented εκδοχή είχε πολύ χαμηλή απόδοση στα notebooks και δεν άξιζε να χρησιμοποιηθεί ως βασικό baseline στο τελικό report.

Τέλος, ενσωματώνουμε ρητά και το tuning της υπερπαραμέτρου C μέσα στη λογική των πειραμάτων: είναι απολύτως αναμενόμενο να αλλάζει το βέλτιστο C από αναπαράσταση σε αναπαράσταση, γιατί το C ελέγχει το trade-off regularization/σφάλματος και η «κλίμακα» και η φύση των χαρακτηριστικών διαφέρει δραστικά (sparse υψηλής διάστασης TF-IDF έναντι dense embeddings μετά από pooling και scaling). Στο __main__ εκτελούμε διαδοχικά όλα τα σενάρια (TF-IDF, TF-IDF augmented, Word2Vec, Word2Vec augmented, GloVe augmented) ώστε να παίρνουμε συγκρίσιμα αποτελέσματα με κοινή διαδικασία εκπαίδευσης και ίδια μορφή αξιολόγησης.

7.1.3 SVM ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΜΠΕΡΑΣΜΑΤΑ

Συγκρίθηκαν πέντε προσεγγίσεις με Linear SVM (εξαιρέθηκε η προσέγγιση χωρίς augmentaion και GloVe embeddings που είχε ήδη αποδειχθεί η αναποτελεσματικότητά της), που διαφέρουν ως προς το feature extraction και το αν χρησιμοποιείται augmented training set, και αναφέρθηκαν τα βασικά aggregate metrics του classification report (accuracy, macro avg, weighted avg, όπου το macro avg είναι unweighted μέσος όρος ανά κλάση και το weighted avg είναι support-weighted μέσος όρος ανά κλάση):

(1) Linear SVM + TF-IDF πέτυχε την καλύτερη συνολική επίδοση με accuracy=0.859, macro avg F1=0.8009 και weighted avg F1=0.8578·

(2) Linear SVM + TF-IDF (augmented) υποχώρησε σε accuracy=0.842, macro avg F1=0.7759 και weighted avg F1=0.8395·

(3) Linear SVM + Word2Vec (mean+max) είχε σαφώς χαμηλότερη απόδοση με accuracy=0.500, macro avg F1=0.4040 και weighted avg F1=0.5050·


(4) Linear SVM + Word2Vec (mean+max, 200 dims, augmented) βελτιώθηκε έναντι της μη-augmented εκδοχής αλλά παρέμεινε χαμηλά (accuracy=0.534, macro avg F1=0.5074, weighted avg F1=0.5409)·

(5) Linear SVM + GloVe (200 dims, augmented) εμφάνισε παρόμοια εικόνα (accuracy=0.529, macro avg F1=0.4846, weighted avg F1=0.5473), με το συνολικό συμπέρασμα ότι ο συνδυασμός TF-IDF με Linear SVM υπερέχει σημαντικά των pooled static embeddings στις συγκεκριμένες συνθήκες αξιολόγησης και για αυτό θα γίνει εκτενής αναφορά σε αυτά τα μοντέλα.

===== Linear SVM (TF-IDF) AUGMENTED Train → Test =====					===== Linear SVM (TF-IDF) Train → Test =====				
Train X: (32172, 20000) Test X: (2000, 20000)					Train X: (16000, 20000) Test X: (2000, 20000)				
Classification report (TEST):					Classification report (TEST):				
	precision	recall	f1-score	support		precision	recall	f1-score	support
0	0.8652	0.8950	0.8799	581	0	0.8986	0.9002	0.8994	581
1	0.8615	0.9036	0.8820	695	1	0.8581	0.9223	0.8890	695
2	0.7114	0.6667	0.6883	159	2	0.7466	0.6855	0.7148	159
3	0.8523	0.8182	0.8349	275	3	0.8842	0.8327	0.8577	275
4	0.8160	0.7723	0.7936	224	4	0.8670	0.7857	0.8244	224
5	0.7111	0.4848	0.5766	66	5	0.6349	0.6061	0.6202	66
accuracy			0.8420	2000	accuracy			0.8590	2000
macro avg	0.8029	0.7568	0.7759	2000	macro avg	0.8149	0.7888	0.8009	2000
weighted avg	0.8393	0.8420	0.8395	2000	weighted avg	0.8582	0.8590	0.8578	2000
Confusion matrix (TEST):					Confusion matrix (TEST):				
[[520 22 3 21 15 0]					[[523 25 5 16 9 3]				
[18 628 36 3 5 5]					[13 641 30 3 1 7]				
[9 42 106 1 0 1]					[3 43 109 2 0 2]				
[27 13 2 225 7 1]					[22 15 1 229 8 0]				
[23 9 2 11 173 6]					[18 10 1 8 176 11]				
[4 15 0 3 12 32]]					[3 13 0 1 9 40]]				

Σχήμα 7: Συγκριτική απόδοση Linear SVM (TF-IDF) vs Linear SVM (TF-IDF) augmented

Πρακτικά, η αύξηση (augmentation) μπορεί να μην βοηθήσει όταν τα συνθετικά ή επαναδειγματοληπτημένα παραδείγματα δεν αντιπροσωπεύουν καλά την πραγματική κατανομή του test (distribution shift) ή όταν “αλλοιώνουν” τα διακριτικά TF-IDF μοτίβα που εκμεταλλεύεται ο γραμμικός ταξινομητής, οδηγώντας σε χειρότερη γενίκευση και σε περισσότερες συγχύσεις μεταξύ κλάσεων. Επιπλέον, αν το augmentation εισάγει έστω και μικρό label noise ή μη-ρεαλιστική γλωσσική παραλλαγή, ο Linear SVM μπορεί να μετακινήσει το decision boundary με τρόπο που μειώνει την καθαρότητα (precision) ή/και την κάλυψη (recall) συγκεκριμένων κλάσεων, κάτι που τελικά αποτυπώνεται ως πτώση τόσο στο macro avg όσο και στο weighted avg στο test.



Σχήμα 8: Πίνακας Σύγχυσης του βέλτιστου μοντέλου (Linear SVM+ TF-IDF).

Από τα αποτελέσματα του Linear SVM με TF-IDF (balanced, C=10.0) προκύπτει ότι το μοντέλο ταξινομεί ιδιαίτερα αποτελεσματικά τις συχνότερες κλάσεις, με πολύ ισχυρές σωστές προβλέψεις στη διαγώνιο για τα sadness (531) και joy (663), ενώ παράλληλα διατηρεί ικανοποιητική επίδοση και σε λιγότερο συχνές κατηγορίες όπως fear (162) και surprise (28), στοιχείο που υποδηλώνει βελτιωμένη κάλυψη πέρα από τις πλειοψηφικές κλάσεις. Τα σφάλματα συγκεντρώνονται κυρίως σε ζεύγη συναισθημάτων με σημασιολογική εγγύτητα, με χαρακτηριστικές συγχύσεις μεταξύ joy και love (π.χ. αρκετές περιπτώσεις love→joy) καθώς και μεταξύ sadness και fear, κάτι που είναι αναμενόμενο σε tasks emotion classification όπου οι γλωσσικές ενδείξεις συχνά επικαλύπτονται και οι αποφάσεις του ταξινομητή αποτυπώνονται ως εκτός-διαγωνίου μάζα στον confusion matrix.

7.2.1 XGBoost (eXtreme Gradient Boosting)

Το XGBoost επιλέχθηκε ως το κύριο μοντέλο μας για την κατηγοριοποίηση, καθώς αποτελεί έναν από τους πιο αποδοτικούς αλγορίθμους gradient boosting, ικανό να διαχειρίζεται αραιά δεδομένα (sparse data) και να αποφεύγει το overfitting μέσω ενσωματωμένων μηχανισμών regularization. Στην υλοποίησή μας χρησιμοποιήσαμε τον `XGBClassifier` με αντικειμενική συνάρτηση `multi:softmax` για την πολυταξική ταξινόμηση των 6 συναισθημάτων.

Πειραματική Διαδικασία και Data Augmentation Δεδομένης της ανισορροπίας των κλάσεων που παρατηρήθηκε στο EDA (με την κλάση "Joy" να υπερτερεί συντριπτικά της κλάσης "Surprise"), η απλή εκπαίδευση του μοντέλου οδηγούσε σε χαμηλή ανάκληση (recall) στις μειοψηφικές κλάσεις. Για να αντιμετωπίσουμε αυτό το πρόβλημα, δεν αρκεστήκαμε μόνο στη ρύθμιση των υπερ-παραμέτρων του μοντέλου (όπως `max_depth=6`, `learning_rate=0.1`), αλλά εφαρμόσαμε μια τεχνική Data Augmentation (Επαύξηση Δεδομένων).

Συγκεκριμένα, σχεδιάσαμε ένα πείραμα δύο φάσεων (`run_all_experiments`):


- **Original Training:** Εκπαίδευση του XGBoost στο αρχικό dataset.
- **Augmented Training:** Εφαρμογή της συνάρτησης `class_balanced_augment`, η οποία δημιουργεί συνθετικά δεδομένα για τις κλάσεις που υστερούν, ώστε να εξισορροπηθεί το dataset πριν την εκπαίδευση.

Εκπαιδεύσαμε το XGBoost ξεχωριστά πάνω και στα τρία είδη χαρακτηριστικών που εξήγαμε (TF-IDF, Word2Vec Mean+Max, GloVe) για να συγκρίνουμε την απόδοση. Τα αποτελέσματα έδειξαν ότι, ενώ το Word2Vec επωφελήθηκε περισσότερο από τη διαδικασία του augmentation, ο συνδυασμός **XGBoost + TF-IDF** παρέμεινε η πιο αποδοτική και στιβαρή προσέγγιση συνολικά.

7.2.2 Πειραματικά Αποτελέσματα και Αξιολόγηση XGBoost

Για την αξιολόγηση του XGBoost, εκτελέσαμε μια σειρά πειραμάτων συγκρίνοντας τρεις διαφορετικές μεθόδους αναπαράστασης κειμένου (TF-IDF, Custom Word2Vec, GloVe) σε δύο σενάρια εκπαίδευσης: (α) με το αρχικό ανισοβαρές dataset και (β) με το επαυξημένο (augmented) dataset.

Σύγκριση Μεθόδων Εξαγωγής Χαρακτηριστικών: Όπως φαίνεται στα διαγράμματά μας, η μέθοδος TF-IDF παρείχε ένα ισχυρό baseline (86.0%), κάτι που είναι αναμενόμενο σε προβλήματα ταξινόμησης κειμένου όπου συγκεκριμένες λέξεις-κλειδιά είναι ισχυροί δείκτες του συναισθήματος. Ωστόσο, η δική μας παραμετροποιημένη υλοποίηση του Word2Vec (με concatenation Mean & Max vectors) πέτυχε αξιόλογα αποτελέσματα, αποδεικνύοντας ότι το μοντέλο κατάφερε να συλλάβει σημασιολογικές σχέσεις, παρόλο που σε απόλυτα νούμερα δεν ξεπέρασε το TF-IDF. Αντιθέτως, τα GloVe embeddings υστέρησαν σε απόδοση, αν και το XGBoost κατάφερε να ανακτήσει μέρος της πληροφορίας μέσω των μη γραμμικών του δέντρων.




Σχήμα 9: Συγκριτική απόδοση XGBoost (Original vs Augmented Data) ανά μέθοδο.

Η Επίδραση του Data Augmentation: Το πιο σημαντικό εύρημα της ανάλυσής μας ήταν η θετική επίδραση της τεχνικής Data Augmentation. Όπως παρατηρούμε στον πίνακα αποτελεσμάτων, η εφαρμογή augmentation οδήγησε σε αύξηση της επίδοσης, ιδιαίτερα στις μειοψηφικές κλάσεις (Surprise, Love). Ενώ στο αρχικό dataset το μοντέλο έτεινε να κάνει bias υπέρ των κλάσεων Joy και Sadness, η χρήση συνθετικών δεδομένων βοήθησε το XGBoost να γενικεύσει καλύτερα, ανεβάζοντας τη συνολική ακρίβεια του βέλτιστου μοντέλου (TF-IDF) στο **88.0%** και βελτιώνοντας αισθητά το Word2Vec κατά **11.3%**.

	precision	recall	f1-score	support
0	0.932971	0.886403	0.909091	581.00
1	0.935737	0.858993	0.895724	695.00
2	0.697115	0.911950	0.790191	159.00
3	0.862191	0.887273	0.874552	275.00
4	0.900000	0.883929	0.891892	224.00
5	0.616162	0.924242	0.739394	66.00
accuracy	0.880000	0.880000	0.880000	0.88
macro avg	0.824029	0.892131	0.850141	2000.00
weighted avg	0.891302	0.880000	0.882718	2000.00

Σχήμα 10: Αναλυτικά αποτελέσματα (Precision, Recall, F1) για το βέλτιστο μοντέλο (XGBoost + TF-IDF Augmented).

Ανάλυση Σφαλμάτων (Confusion Matrix): Εξετάζοντας τον Πίνακα Σύγχυσης του βέλτιστου μοντέλου μας, παρατηρούμε ότι τα περισσότερα σφάλματα εντοπίζονται μεταξύ σημασιολογικά συγγενών συναισθημάτων. Για παράδειγμα, υπάρχει μια τάση σύγχυσης μεταξύ Love και Joy, καθώς και οι δύο κλάσεις μοιράζονται θετικό λεξιλόγιο. Αντίστοιχα, το Anger συγχέεται περιστασιακά με το Sadness. Παρόλα αυτά, το μοντέλο διατηρεί υψηλή διακριτική ικανότητα στις ξεκάθαρες συναισθηματικές εκφράσεις.



Σχήμα 11: Πίνακας Σύγχυσης του βέλτιστου μοντέλου (XGBoost + TF-IDF με Augmentation).

7.3 LOGISTIC REGRESSION

7.3.1 Θεωρητικό Υπόβαθρο

Η λογιστική παλινδρόμηση αποτελεί γραμμικό μοντέλο supervised learning που χρησιμοποιείται για προβλήματα ταξινόμησης. Εκτιμά πιθανότητες ενός δείγματος και αναλόγως αυτή, το δείγμα τοποθετείται στην αντίστοιχη κλάση.

Αρχικά, έχουμε τον γραμμικό συνδυασμό των χαρακτηριστικών του δείγματος:

$$z = w^T x + b,$$

Όπου x είναι το διάνυσμα των χαρακτηριστικών, w τα βάρη του μοντέλου και b ο όρος μετατόπισης. Στην περίπτωση της δυαδικής ταξινόμησης χρησιμοποιείται η σιγμοειδής συνάρτηση (sigmoid), η οποία περιορίζει τα αποτελέσματα στο $(0,1)$ και επιτρέπει την ερμηνεία του δείγματος ως πιθανότητα.

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

Για προβλήματα πολυταξικής ταξινόμησης, όπως η κατηγοριοποίηση συναισθήματος στην παρούσα εργασία, επεκτείνουμε την δυαδική σε multinomial μορφή. Το μοντέλο υπολογίζει έναν γραμμικό συνδυασμό για κάθε κλάση k :

$$z_k = w_k^T x + b_k,$$

Δηλαδή, έχουμε ένα ενιαίο μοντέλο που μαθαίνει όλες τις κλάσεις μαζί. Έπειτα εφαρμόζουμε softmax, ώστε να παραχθεί η κανονικοποιημένη κατανομή πιθανοτήτων.

$$P(y = k | x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

Η τελική πρόβλεψη κατηγοριοποίησης προκύπτει επιλέγοντας την κλάση με την μέγιστη εκτιμώμενη πιθανότητα. Η εκπαίδευση το μοντέλου πραγματοποιείται με την ελαχιστοποίηση της συνάρτησης κόστους η οποία είναι η cross-entropy:

$$L = - \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(y_{ik})$$

Στο πλαίσιο αυτής της εργασίας, η Logistic Regression χρησιμοποιήθηκε ως βασικό μοντέλο αναφοράς, καθώς συνδυάζεται πολύ με το TF-IDF. Η γραμμική της φύση και η ερμηνευσιμότητα των παραμέτρων της επιτρέπουν τη μελέτη της επίδρασης διαφορετικών αναπαραστάσεων χαρακτηριστικών, καθώς και την αξιολόγηση της συμβολής του data augmentation στην απόδοση του ταξινομητή.

7.3.2 Πειράματα με Logistic Regression

Για τη μελέτη της συμπεριφοράς της Logistic Regression στην multilabel κατηγοριοποίηση συναισθήματος, πραγματοποιήθηκε σειρά πειραμάτων με διαφορετικές μεθόδους feature extraction, τόσο στο αρχικό όσο και στο augmented dataset.

Συγκεκριμένα εξετάστηκαν οι ακόλουθοι συνδυασμοί:


- **Logistic Regression με TF-IDF αναπαράσταση**, εκπαιδευμένη στο αρχικό σύνολο δεδομένων αλλά και στο augmented
- **Logistic Regression με GloVe embeddings**, όπου κάθε κείμενο αναπαρίσταται μέσω πυκνών διανυσμάτων λέξεων, τόσο χωρίς όσο και με εφαρμογή data augmentation.
- **Logistic Regression με Word2Vec embeddings**, με χρήση συνάθροισης (mean και max pooling) των διανυσμάτων λέξεων, τόσο στο αρχικό όσο και στο εμπλουτισμένο σύνολο εκπαίδευσης.

Στις περιπτώσεις των GloVe και Word2Vec, εφαρμόστηκε κανονικοποίηση των χαρακτηριστικών και επίσης δημιουργήθηκε και μια λειτουργία η οποία μετατρέπει padded sequences προτάσεων σε αριθμητικά vectors τα οποία είναι το κατάλληλο input για τέτοιου είδους classifiers.

7.3.3 Ανάλυση των αποτελεσμάτων

Τα καλύτερα αποτελέσματα τα είχαμε στην περίπτωση του TF-IDF + Augmented Data. Για τον λόγο αυτό επιλέχθηκε ως η βέλτιστη περίπτωση και αναλύεται περαιτέρω μέσω γραφικών απεικονίσεων. Η συνολική επίδοση αποτυπώνεται και στο macro-averaged F1-score, το οποίο είναι 0.8252. Επίσης το accuracy είναι 0.8725.

Confusion Matrix (Test - TF-IDF + Logistic Regression + Augmented Data)



Σχήμα 12: Confusion Matrix για TF-IDF + Logistic Regression (Augmented Train Set).

Από τον πίνακα αυτό παρατηρείται ότι το μοντέλο ταξινομεί με υψηλή ακρίβεια τις πλειοψηφικές κλάσεις, όπως το *joy* και το *sadness*, ενώ παρουσιάζει βελτιωμένη συμπεριφορά και σε λιγότερο συχνές κατηγορίες, όπως το *fear* και το *surprise*. Τα περισσότερα σφάλματα εντοπίζονται μεταξύ συναισθημάτων με εννοιολογική εγγύτητα, όπως *sadness* και *fear* ή *joy* και *love*, γεγονός που είναι αναμενόμενο στο πλαίσιο της κατηγοριοποίησης συναισθήματος.

Σχήμα 13: *Classification Report για TF-IDF + LR (augmented)*

	precision	recall	f1-score	support
0	0.920635	0.898451	0.909408	581.0000
1	0.898426	0.903597	0.901004	695.0000
2	0.718919	0.836478	0.773256	159.0000
3	0.857143	0.872727	0.864865	275.0000
4	0.864734	0.799107	0.830626	224.0000
5	0.693548	0.651515	0.671875	66.0000
accuracy	0.872500	0.872500	0.872500	0.8725
macro avg	0.825568	0.826979	0.825172	2000.0000
weighted avg	0.874396	0.872500	0.872877	2000.0000

Παραπάνω παρουσιάζεται το αναλυτικό classification report για τη βέλτιστη πειραματική ρύθμιση. Παρατηρείται ότι οι πλειοψηφικές κλάσεις (*sadness*, *joy*) παρουσιάζουν υψηλά F1-scores, ενώ οι μειοψηφικές κατηγορίες (*love*, *surprise*) εμφανίζουν χαμηλότερες τιμές, γεγονός αναμενόμενο λόγω περιορισμένου αριθμού δειγμάτων. Παρ' όλα αυτά, το macro-averaged F1-score ίσο με 0.825 υποδηλώνει καλή και ισορροπημένη συνολική απόδοση.

8 INFERENCE

8.1 Σκοπός

Ο στόχος εδώ είναι η αξιοποίηση των εκπαιδευμένων μοντέλων για την παραγωγή προβλέψεων συναισθήματος σε νέα δεδομένα. Η ιδέα είναι ότι το inference εφαρμόζεται σε κριτικές ταινιών (movie reviews), προσομοιώνοντας ένα ρεαλιστικό σενάριο χρήσης όπου το σύστημα δέχεται ως είσοδο ένα κείμενο και επιστρέφει την προβλεπόμενη κατηγορία συναισθήματος.

Οι προβλέψεις αντιστοιχίζονται σε μία από τις έξι διαθέσιμες κατηγορίες συναισθήματος (sadness, joy, love, anger, fear, surprise). Με τον τρόπο αυτό, αξιολογείται η δυνατότητα του μοντέλου να γενικεύει πέρα από το αρχικό σύνολο δεδομένων εκπαίδευσης και να αποδίδει προβλέψεις σε διαφορετικά δεδομένα.

8.2 Διαδικασία

Στη διαδικασία ακολουθούμε τα ίδια βήματα με την εκπαίδευση, ώστε να διασφαλίζεται συνέπεια στο μετασχηματισμό των δεδομένων:

1. **Είσοδος κειμένου** (ένα ή περισσότερα reviews/προτάσεις).
2. **Ίδια προεπεξεργασία** κειμένου με αυτή που εφαρμόστηκε στο training (lowercase, καθαρισμός, κ.λπ.).
3. **Φόρτωση αποθηκευμένων artifacts** (μοντέλο + μετασχηματιστής χαρακτηριστικών + αντιστοίχιση labels), ώστε να μην απαιτείται επανεκπαίδευση.
4. **Μετατροπή κειμένου σε διανυσματική αναπαράσταση** μέσω του ήδη εκπαιδευμένου feature extractor (π.χ. TF-IDF vectorizer).

5. **Πρόβλεψη κλάσης** από το μοντέλο και παραγωγή πιθανών βοηθητικών εξόδων (π.χ. confidence/πιθανότητες όπου υποστηρίζεται).
6. **Αποθήκευση αποτελεσμάτων** (π.χ. σε JSON) για αναπαραγωγιμότητα και εύκολη αξιολόγηση.

8.3 Σενάριο Χρήσης

Για να δείξουμε λοιπόν ότι το σύστημα έχει και πρακτική εφαρμογή, υλοποιήθηκαν scripts inference τα οποία εφαρμόζουν την παραπάνω διαδικασία σε νέα κείμενα από movie reviews. Πραγματοποιήθηκε generalization σε κείμενα διαφορετικού ύφους και πηγής (imdb movie reviews dataset), ώστε να εξεταστεί η συμπεριφορά του μοντέλου.

8.4 Αποτελέσματα Inference σε κριτικές ταινιών

Για κάθε κείμενο, το σύστημα επιστρέφει:

1. Την προβλεπόμενη κατηγορία συναισθήματος
2. Έναν δείκτη εμπιστοσύνης (confidence) που προκύπτει από την πιθανότητα της επικρατέστερης κλάσης
3. Μία ένδειξη “accepted/uncertain” με βάση προκαθορισμένο κατώφλι εμπιστοσύνης.

Τα αποτελέσματα δείχνουν ότι, σε περιπτώσεις όπου το sentiment είναι σαφές, το μοντέλο αποδίδει συνεπείς προβλέψεις με σχετικά υψηλή εμπιστοσύνη (π.χ. joy σε έντονα θετικές/ενθουσιώδεις κριτικές). Παράλληλα, σε πιο σύνθετα κείμενα, η εμπιστοσύνη μειώνεται και η πρόβλεψη χαρακτηρίζεται ως “uncertain”, γεγονός που είναι αναμενόμενο όταν το μοντέλο εφαρμόζεται σε δεδομένα διαφορετικού ύφους και λεξιλογίου από αυτά της εκπαίδευσης.

Επιπλέον, παρατηρείται ότι ορισμένες κριτικές με έντονα αρνητικό περιεχόμενο κατατάσσονται σε joy με χαμηλή εμπιστοσύνη. Αυτό υποδεικνύει ότι το λεξιλόγιο των IMDb reviews (π.χ. ειρωνεία, περιγραφές πλοκής, έντονα αφηγηματικό ύφος ή λέξεις εκτός του αρχικού λεξιλογίου) μπορεί να οδηγήσει σε μετατόπιση της κατανομής εισόδου (domain shift), επηρεάζοντας την αξιοπιστία των προβλέψεων. Η ύπαρξη του confidence threshold είναι χρήσιμη σε αυτό το σενάριο, καθώς επιτρέπει την επισήμανση αβέβαιων προβλέψεων και θα μπορούσε σε πραγματική εφαρμογή να ενεργοποιεί χειροκίνητο έλεγχο ή δεύτερο μοντέλο.

9 Βιβλιογραφία

- Διαφάνειες μαθήματος
- <https://www.geeksforgeeks.org/>
- <https://stackoverflow.com>
- <https://huggingface.co/docs/datasets/en/cache>
- eb.stanford.edu/~jurafsky/slp3/
- <https://zenodo.org/records/4925376>